Cuantificación de Incertidumbre en Clasificación Histopatológica

Elena Ardura Carnicero
Universidad Pontificia Comillas
202111181@alu.comillas.edu

Victoria García Martínez-Echevarría
Universidad Pontificia Comillas
202112284@alu.comillas.edu

Abstract

La adopción clínica de sistemas de aprendizaje profundo en anatomía patológica se ve limitada no tanto por la precisión de los modelos, sino por la incapacidad de estos de señalar cuándo no están seguros de sus predicciones. En este trabajo se comparan empíricamente tres modelos (dos de ellos con cuantificación de incertidumbre) que parten del mismo clasificador de referencia (ResNet18 preentrenada) aplicado al dataset *Histopathologic Cancer Detection*: (i) una red determinista entrenada como estimador máximo a posteriori (MAP); (ii) una aproximación de Laplace *post-hoc* sobre la última capa, con Hessiano factorizado por Kronecker (KFAC) y precisión del prior optimizada por verosimilitud marginal; y (iii) Monte Carlo Dropout con $T{=}50$ pasadas estocásticas en inferencia. Los tres modelos se evalúan en términos de discriminación (AUC-ROC, F1), calibración probabilística (Expected Calibration Error, Brier Score, log-verosimilitud negativa) y utilidad clínica mediante un análisis de triaje basado en incertidumbre epistémica.

1 Introducción

La detección automática de tejido tumoral en parches histopatológicos es uno de los casos de uso más consolidados del aprendizaje profundo en medicina. Sin embargo, en este contexto no basta con obtener una alta precisión agregada: una probabilidad puntual $\hat{p}(y = 1 \mid \mathbf{x})$ no informa de la fiabilidad de la predicción y puede asignar niveles de confianza similares a casos prototípicos y a muestras morfológicamente ambiguas. Esta limitación es especialmente relevante en oncología, donde el coste de un falso negativo es elevado y una predicción incorrecta puede tener consecuencias clínicas importantes.

El enfoque bayesiano ofrece una forma natural de abordar este problema. En lugar de producir una única estimación de los pesos del modelo, permite razonar en términos de distribuciones predictivas y, con ello, cuantificar incertidumbre. Esta información puede utilizarse de forma operativa en una política de triaje: las muestras con mayor incertidumbre epistémica se derivan a revisión humana, mientras que los casos más confiables pueden servir como apoyo al cribado. Desde esta perspectiva, el valor práctico de los modelos probabilísticos no se reduce a mejorar ligeramente la discriminación, sino a producir probabilidades mejor calibradas y una señal de incertidumbre útil para la toma de decisiones.

En este trabajo comparamos empíricamente tres modelos sobre el dataset *Histopathologic Cancer Detection*, construidos sobre una misma ResNet18 preentrenada. El primero es un clasificador determinista entrenado como estimador máximo a posteriori (MAP); el segundo, una aproximación de Laplace [Daxberger et al., 2021], *post-hoc*, aplicada a la última capa; y el tercero, una variante con MC Dropout [Gal and Ghahramani, 2016] para inferencia aproximada por Monte Carlo. La comparación se realiza en términos de discriminación, calibración probabilística y utilidad para triaje basada en incertidumbre. Además, analizamos el coste computacional de cada enfoque para valorar su posible despliegue y acompañamos el estudio con código reproducible y una demo interactiva.

Probabilistic Artificial Intelligence – MsC in Advanced Artificial Intelligence, Universidad Pontificia Comillas.

2 Formulación del problema

2.1 Modelo probabilístico

Disponemos de un conjunto de datos (dataset *Histopathologic Cancer Detection*) $\mathcal{D} = \{(\mathbf{x}_i, y_i)\}_{i=1}^{N}$ con imágenes $\mathbf{x}_i \in \mathbb{R}^{3\times96\times96}$ y etiquetas binarias $y_i \in \{0, 1\}$ que indican la presencia o ausencia de tejido tumoral en la región central (32x32) de la imagen. Modelizamos la verosimilitud como categórica sobre dos clases,

$$p(y \mid \mathbf{x}, \boldsymbol{\omega}) \;=\; \mathrm{Cat}\big(y \,\big|\, \mathrm{softmax}(f_{\boldsymbol{\omega}}(\mathbf{x}))\big), \tag{1}$$

donde $f_{\boldsymbol{\omega}} : \mathbb{R}^{3\times96\times96} \to \mathbb{R}^2$ es una red neuronal con pesos $\boldsymbol{\omega} \in \mathbb{R}^P$. Aunque el problema es binario, tomamos la parametrización *softmax* de dos dimensiones por cuestiones de compatibilidad con la librería `laplace-torch` (que asume salida categórica) y con el mecanismo de descomposición de la incertidumbre explicado en la sección 3.6.

Asumimos un prior gaussiano isotrópico sobre los pesos,

$$p(\boldsymbol{\omega}) \;=\; \mathcal{N}\big(\boldsymbol{\omega} \,\big|\, \mathbf{0}, \lambda^{-1}\mathbf{I}\big), \tag{2}$$

con precisión $\lambda > 0$. Para obtener la distribución predictiva bayesiana para una nueva observación $\mathbf{x}^\star$ necesitamos marginalizar sobre el posterior,

$$p(y^\star \mid \mathbf{x}^\star, \mathcal{D}) \;=\; \int p(y^\star \mid \mathbf{x}^\star, \boldsymbol{\omega})\, p(\boldsymbol{\omega} \mid \mathcal{D})\, \mathrm{d}\boldsymbol{\omega}. \tag{3}$$

Para ResNet18, con $P \sim 10^7$ parámetros, ni el posterior $p(\boldsymbol{\omega} \mid \mathcal{D})$ ni la integral (3) admiten forma cerrada. La metodología de este trabajo se centra en cómo aproximar esa integral manteniendo el mayor número posible de garantías bayesianas a un coste computacional aceptable.

2.2 Requisitos del sistema

Requisitos funcionales. El sistema debe proporcionar, para cada imagen, una distribución predictiva $p(y \mid \mathbf{x})$, estimar incertidumbre aleatoria y epistémica, y permitir una regla de derivación a revisión humana en función de la incertidumbre epistémica.

Requisitos no funcionales. Buscamos buena calibración probabilística, latencia de inferencia compatible con un flujo asistido de revisión y un consumo de memoria razonable para hardware convencional. Estos requisitos condicionan la elección del subconjunto de pesos y de la estructura del Hessiano en la aproximación de Laplace.

2.3 Selección de métodos

La literatura ofrece un rango amplio de métodos de inferencia aproximada para redes neuronales bayesianas (BNNs). En el (Anexo A) se resumen los factores que más comprometen la selección, la cual debe ponderar el coste de entrenamiento, el coste de inferencia, la necesidad o no de reentrenamiento y la fidelidad de la aproximación al posterior.

Tras analizar los modelos estudiados, se optó por seleccionar la aproximación de Laplace y el enfoque de MC Dropout para compararlos en este estudio. El primero es un método *post-hoc* que aprovecha la curvatura real del *loss* en el punto MAP, y el segundo es trivial de implementar sobre cualquier arquitectura que ya incluya *dropout*. Ambos comparten la misma arquitectura troncal y, en el caso de Laplace, el mismo punto MAP, lo que permite atribuir las diferencias observadas casi exclusivamente al mecanismo de cuantificación de incertidumbre. Deep Ensembles y MCMC quedan fuera del alcance por coste computacional; y MFVI se descarta porque requeriría una reimplementación completa del entrenamiento sin asegurar una ventaja teórica sobre Laplace en términos de fidelidad del posterior.

3 Metodología

3.1 Del estimador MAP a las aproximaciones probabilísticas

El punto de partida de nuestro sistema es un clasificador entrenado con entropía cruzada y regularización L_2, lo que admite una interpretación bayesiana inmediata. En efecto, si asumimos un prior

gaussiano isótropo sobre los pesos, $p(\boldsymbol{\omega}) = \mathcal{N}(\mathbf{0}, \lambda^{-1}\mathbf{I})$, entonces minimizar la función de pérdida regularizada equivale a obtener el estimador máximo a posteriori (MAP)

$$\boldsymbol{\omega}^* = \arg\max_{\boldsymbol{\omega}} \left[\log p(\mathcal{D} \mid \boldsymbol{\omega}) + \log p(\boldsymbol{\omega})\right]. \tag{4}$$

A partir de este punto MAP exploramos dos formas distintas de aproximar la distribución posterior sobre los pesos. La aproximación de Laplace construye una Gaussiana local alrededor de $\boldsymbol{\omega}^*$ a partir de la curvatura del log-posterior, mientras que MC Dropout aproxima la predictiva bayesiana mediante múltiples pasadas estocásticas en inferencia. En ambos casos, la predicción final se obtiene promediando múltiples realizaciones del modelo, pero difieren en la forma en que aproximan $p(\boldsymbol{\omega} \mid \mathcal{D})$.

3.2 Arquitectura troncal

Los tres modelos se construyen sobre una misma arquitectura base, concretamente una ResNet18 preentrenada en ImageNet, que actúa como extractor de características para la clasificación binaria de parches histopatológicos. Dada una imagen $\mathbf{x} \in \mathbb{R}^{3\times96\times96}$, el backbone produce un vector de características $g_{\boldsymbol{\phi}}(\mathbf{x}) \in \mathbb{R}^{512}$. Siguiendo una estrategia de *fine-tuning* parcial, congelamos los bloques `conv1`, `bn1`, `layer1` y `layer2`, y entrenamos únicamente `layer3`, `layer4` y la cabeza clasificadora.

El modelo determinista sustituye la capa totalmente conectada original por una proyección lineal

$$f_{\boldsymbol{\omega}}(\mathbf{x}) = \mathbf{W}\, g_{\boldsymbol{\phi}}(\mathbf{x}) + \mathbf{b}, \qquad \mathbf{W} \in \mathbb{R}^{2\times512}, \quad \mathbf{b} \in \mathbb{R}^2, \tag{5}$$

de forma que la salida son dos *logits* compatibles con la verosimilitud categórica de la Sección 2.1.

En MC Dropout mantenemos el mismo backbone, pero reemplazamos la cabeza por un pequeño bloque estocástico

$$h \mapsto q\mathrm{Linear}_{256\to2}\Big(\mathrm{Dropout}_p\big(\mathrm{ReLU}(\mathrm{Linear}_{512\to256}(h))\big)\Big), \qquad p = 0.3, \tag{6}$$

introduciendo así la fuente de aleatoriedad necesaria para la aproximación variacional implícita.

3.3 Modelo determinista: estimación MAP

El clasificador de referencia se entrena minimizando la pérdida *cross-entropy* con regularización L_2:

$$\mathcal{L}(\boldsymbol{\omega}) = -\sum_{i=1}^{N} \log p(y_i \mid \mathbf{x}_i, \boldsymbol{\omega}) + \frac{\lambda}{2}\|\boldsymbol{\omega}\|_2^2, \qquad \lambda = 10^{-4}. \tag{7}$$

Bajo el prior gaussiano isótropo anterior, la minimización de (7) es equivalente a obtener el estimador MAP dado en (4).

Optimizamos (7) con Adam, tasa de aprendizaje inicial 10^{-4} y *weight decay* 10^{-4}. La selección del mejor checkpoint se realiza sobre el AUC de validación. Para estabilizar el entrenamiento usamos dos mecanismos: (i) *early stopping* con paciencia 5 sobre AUC de validación y (ii) `ReduceLROnPlateau` con factor 0.5 y paciencia 3. Cuando hay GPU disponible, el entrenamiento utiliza precisión mixta automática para acelerar el cálculo sin alterar apreciablemente las métricas finales.

Este modelo actúa como *baseline* fuerte y proporciona el punto MAP a partir del cual se construye la aproximación de Laplace.

3.4 Aproximación de Laplace

Aproximación local del posterior. La aproximación de Laplace reemplaza el posterior exacto $p(\boldsymbol{\omega} \mid \mathcal{D})$ por una Gaussiana centrada en el máximo a posteriori ω^*. Si expandimos el log-posterior alrededor de $\boldsymbol{\omega}^*$ mediante Taylor de segundo orden, obtenemos

$$\log p(\boldsymbol{\omega} \mid \mathcal{D}) \approx \log p(\boldsymbol{\omega}^* \mid \mathcal{D}) - \frac{1}{2}(\boldsymbol{\omega} - \boldsymbol{\omega}^*)^\top \mathbf{H}(\boldsymbol{\omega} - \boldsymbol{\omega}^*), \tag{8}$$

donde $\mathbf{H} = -\nabla^2_{\boldsymbol{\omega}} \log p(\boldsymbol{\omega}^* \mid \mathcal{D})$. Exponenciando y renormalizando, el posterior aproximado es

$$q(\boldsymbol{\omega}) = \mathcal{N}\big(\boldsymbol{\omega} \mid \boldsymbol{\omega}^*, \boldsymbol{\Sigma}\big), \qquad \boldsymbol{\Sigma} = (\mathbf{H} + \lambda_{\mathrm{LA}}\mathbf{I})^{-1}, \tag{9}$$

donde λ_{LA} es la precisión del prior efectiva usada por Laplace. Distinguimos λ_{LA} del *weight decay* usado en el entrenamiento: este último fija la regularización del modelo MAP, mientras que λ_{LA} se re-estima después para ajustar la aproximación de Laplace maximizando una verosimilitud marginal aproximada.

Laplace solo sobre la última capa. Aplicar (9) a todos los pesos de una ResNet18 completa es inviable. Por ello descomponemos $\boldsymbol{\omega} = (\boldsymbol{\phi}, \boldsymbol{\psi})$, donde $\boldsymbol{\phi}$ agrupa el backbone y $\boldsymbol{\psi} \in \mathbb{R}^{1026}$ los parámetros de la última capa lineal (512×2 pesos más 2 sesgos). El backbone se trata como extractor determinista fijo y la aproximación se restringe a

$$q(\boldsymbol{\psi}) = \mathcal{N}\big(\boldsymbol{\psi} \mid \boldsymbol{\psi}^*, \boldsymbol{\Sigma}_\psi\big). \tag{10}$$

Esta decisión conserva gran parte de la incertidumbre *task-specific*, al concentrarse en la capa más próxima a la decisión final, con un coste muy inferior al de una aproximación de Laplace sobre la red completa

Curvatura y estructura del Hessiano. Para obtener una aproximación estable del posterior empleamos la matriz *Generalized Gauss–Newton* (GGN),

$$\mathbf{H}_{\mathrm{GGN}} = \sum_{i=1}^{N} \mathbf{J}_\psi(\mathbf{x}_i)^\top \boldsymbol{\Lambda}_i \mathbf{J}_\psi(\mathbf{x}_i), \tag{11}$$

donde $\mathbf{J}_\psi(\mathbf{x}_i)$ es el Jacobiano de los logits respecto a la última capa y $\boldsymbol{\Lambda}_i = -\nabla^2_{\mathbf{f}} \log p(y_i \mid \mathbf{f})$ es el Hessiano negativo de la log-verosimilitud respecto a los logits. Además, utilizamos una estructura Kronecker-factorizada (`kron`) para el bloque de la última capa, lo que reduce el coste de almacenar e invertir la covarianza sin abandonar la estructura correlacional principal del problema.

Ajuste de la precisión del prior. Tras ajustar Laplace sobre el conjunto de entrenamiento, optimizamos λ_{LA} maximizando una aproximación de la log-verosimilitud marginal,

$$\log p(\mathcal{D} \mid \lambda_{\mathrm{LA}}) \approx \log p(\mathcal{D} \mid \boldsymbol{\omega}^*) + \log p(\boldsymbol{\omega}^* \mid \lambda_{\mathrm{LA}}) - \frac{1}{2} \log \det\big(\mathbf{H}_{\mathrm{GGN}} + \lambda_{\mathrm{LA}} \mathbf{I}\big) + \mathrm{const}. \tag{12}$$

Esta etapa constituye una forma de selección de modelo bayesiana *post-hoc* y evita fijar manualmente la escala del prior de Laplace.

Predicción con Laplace. La distribución predictiva exacta bajo (10) sigue siendo intratable, por lo que recurrimos a dos aproximaciones complementarias. Para la probabilidad predictiva media final usamos la regla predictiva tipo GLM con aproximación *probit* sobre la salida linealizada de la última capa. Denotando por $\bar{p}_{\mathrm{LA}}(y = 1 \mid \mathbf{x}, \mathcal{D})$ dicha media,

$$\bar{p}_{\mathrm{LA}}(y = 1 \mid \mathbf{x}, \mathcal{D}) \approx p_{\text{GLM-probit}}(y = 1 \mid \mathbf{x}, \mathcal{D}). \tag{13}$$

Adicionalmente, para cuantificar la incertidumbre epistémica extraemos $T_{\mathrm{LA}} = 100$ muestras posteriores $\boldsymbol{\psi}^{(t)} \sim q(\boldsymbol{\psi})$ y calculamos

$$p_t(\mathbf{x}) = p\Big(y = 1 \mid \mathbf{x}, \boldsymbol{\psi}^{(t)}\Big), \qquad t = 1, \ldots, T_{\mathrm{LA}}. \tag{14}$$

Esta formulación híbrida mejora la calibración de las probabilidades sin renunciar al análisis muestral de incertidumbre.

3.5 MC Dropout como inferencia variacional

MC Dropout aproxima la predictiva bayesiana manteniendo activas las máscaras de dropout en inferencia. Siguiendo la interpretación variacional de Gal and Ghahramani [2016], cada máscara induce una realización de un posterior aproximado $q_{\mathrm{drop}}(\boldsymbol{\omega})$. En nuestro caso, la estocasticidad se introduce exclusivamente en la cabeza clasificadora de (6), mientras que el backbone permanece determinista.

En tiempo de test fijamos la red en modo evaluación para no actualizar las estadísticas de BatchNorm, pero reactivamos exclusivamente las capas `Dropout`. De este modo, cada pasada hacia delante usa

una máscara distinta y genera una muestra implícita del posterior aproximado. La predictiva se estima por Monte Carlo como

$$\bar{p}_{\mathrm{MC}}(y=1 \mid \mathbf{x}, \mathcal{D}) \approx \frac{1}{T_{\mathrm{MC}}} \sum_{t=1}^{T_{\mathrm{MC}}} p\Big(y=1 \mid \mathbf{x}, \boldsymbol{\omega}^{(t)}\Big), \qquad \boldsymbol{\omega}^{(t)} \sim q_{\mathrm{drop}}(\boldsymbol{\omega}), \tag{15}$$

con $T_{\mathrm{MC}} = 50$ pasadas estocásticas. A diferencia de Laplace, este enfoque no es *post-hoc*, ya que exige haber entrenado una arquitectura con dropout.

3.6 Descomposición de la incertidumbre y política de triaje

Para cada entrada $\mathbf{x}$ y cada muestra estocástica t definimos la probabilidad de clase positiva $p_t(\mathbf{x}) = p(y=1 \mid \mathbf{x}, \boldsymbol{\omega}^{(t)})$. En MC Dropout empleamos la descomposición habitual de la varianza predictiva,

$$u_{\mathrm{epi}}(\mathbf{x}) = \mathrm{Var}_t[p_t(\mathbf{x})]\,, \tag{16}$$

$$u_{\mathrm{ale}}(\mathbf{x}) = \frac{1}{T} \sum_{t=1}^{T} p_t(\mathbf{x})\big(1 - p_t(\mathbf{x})\big), \tag{17}$$

$$u_{\mathrm{tot}}(\mathbf{x}) = u_{\mathrm{epi}}(\mathbf{x}) + u_{\mathrm{ale}}(\mathbf{x}). \tag{18}$$

La componente epistémica mide el desacuerdo entre muestras del posterior aproximado, mientras que la aleatoria captura la incertidumbre intrínseca de una Bernoulli condicional.

En Laplace usamos una variante coherente con la evaluación final del sistema. La incertidumbre epistémica se estima igualmente mediante $\mathrm{Var}_t[p_t(\mathbf{x})]$, pero la componente aleatoria se calcula a partir de la probabilidad media final obtenida por la regla GLM-probit:

$$u_{\mathrm{ale}}^{\mathrm{LA}}(\mathbf{x}) = \bar{p}_{\mathrm{LA}}(\mathbf{x})\,(1 - \bar{p}_{\mathrm{LA}}(\mathbf{x}))\,. \tag{19}$$

Con ello, la cantidad mostrada al usuario sigue siendo $u_{\mathrm{tot}} = u_{\mathrm{epi}} + u_{\mathrm{ale}}$, aunque la media predictiva y la dispersión posterior provengan de aproximaciones complementarias.

Finalmente, convertimos la incertidumbre en una acción operativa mediante una política de rechazo selectivo. Una muestra se deriva a revisión humana cuando su incertidumbre epistémica excede un umbral τ_u calibrado en validación:

$$\mathrm{refer}(\mathbf{x}) = \mathbb{I}[u_{\mathrm{epi}}(\mathbf{x}) > \tau_u]\,. \tag{20}$$

En la práctica, estimamos τ_u como el percentil 85 de la distribución de incertidumbre epistémica en validación para cada método. Esto evita comparar en una misma escala magnitudes cuya calibración numérica depende del mecanismo de inferencia empleado.

4 Configuración experimental

4.1 Dataset y preprocesado

El dataset empleado es *Histopathologic Cancer Detection*, compuesto por imágenes de 96×96 píxeles extraídas de cortes histológicos teñidos con hematoxilina-eosina (método de tinción estándar en este área). La etiqueta que acompaña a cada imagen indica si existe tejido tumoral en la región central de 32×32. Este dataset, al igual muchos otros que contienen datos clínicos reales, presenta algunas deficiencias como desbalanceo de clases (en este caso moderado, habiendo aproximadamente un 40% de muestras positivas, i.e., con tejido tumoral), variabilidad de tinción entre laboratorios, artefactos al digitalizar las muestras, etcétera.

División. Separamos el conjunto en 70% entrenamiento, 15% validación y 15% test mediante división estratificada (con el argumento `stratify=label` en la función `train_test_split`), preservando la proporción de clases en cada partición. La semilla aleatoria se fija (`RANDOM_SEED=42`) en todas las librerías y se configura el backend de PyTorch con `cudnn.deterministic=True` para garantizar reproducibilidad hasta el nivel de las convoluciones.

Table 1: Hiperparámetros y su interpretación bayesiana.

Componente	Hiperparámetro	Valor	Interpretación
Entrenamiento	`LEARNING_RATE`	10^{-4}	Tasa de aprendizaje
Entrenamiento	`BATCH_SIZE`	64	Tamaño del lote
Entrenamiento	`NUM_EPOCHS`	25 (máx.)	Con *early stopping*
Entrenamiento	`PATIENCE`	5	Paciencia sobre AUC de validación
Prior	`WEIGHT_DECAY` $= \lambda$	10^{-4}	Precisión del prior $p(\omega) = \mathcal{N}(\mathbf{0}, \lambda^{-1}\mathbf{I})$
MC Dropout	`DROPOUT_RATE` $= p$	0.3	Familia variacional Bernoulli
MC Dropout	`MC_SAMPLES` $= T$	50	Muestras de (15)
Laplace	`LAPLACE_SUBSET`	`last_layer`	Tractabilidad de $\mathbf{\Sigma}$
Laplace	`LAPLACE_HESSIAN`	`kron`	Factorización KFAC del Hessiano
Laplace	`LAPLACE_SAMPLES`	100	Muestras de pesos en inferencia
Laplace	Precisión del prior	Optimizada	Verosimilitud marginal (12)
Triaje	`UNCERTAINTY_THRESHOLD`	0.05	Umbral τ_u para derivación
Calibración	`ECE_NUM_BINS`	15	Granularidad del diagrama de fiabilidad

Aumento de datos. Durante el entrenamiento aplicamos *flips* horizontales y verticales aleatorios, rotaciones de hasta 20° y perturbaciones de brillo, contraste, saturación y matiz (`ColorJitter`). La invarianza a la orientación se justifica por la ausencia de una dirección canónica en imágenes histológicas; las perturbaciones cromáticas representan la variabilidad de tinción entre laboratorios, que es una de las principales fuentes de *distribution shift* en este dominio. En validación y test aplicamos únicamente la normalización con las estadísticas de ImageNet, para mantener la coherencia con la inicialización del *backbone*.

4.2 Hiperparámetros

La Tabla 1 resume los hiperparámetros empleados y su interpretación probabilística.

4.3 Protocolo de evaluación

Métricas *offline* de discriminación. AUC-ROC, *accuracy*, F1-score con umbral 0.5, *precision* y *recall* calculadas sobre el conjunto de test.

Métricas *offline* de calibración.

- **Log-verosimilitud negativa**: Penaliza simultáneamente errores y sobreconfianza.

$$NLL = -\frac{1}{N_{\text{test}}} \sum_i \log p(y_i \mid \mathbf{x}_i, \mathcal{D}). \tag{21}$$

- **Brier score**: Combina en una única cifra calibración y resolución [Gneiting and Raftery, 2007].

$$\text{BS} = \frac{1}{N_{\text{test}}} \sum_i (p_i - y_i)^2. \tag{22}$$

- **Expected Calibration Error (ECE)**: Mide la discrepancia entre la confianza predicha y la precisión real del modelo. Las predicciones se agrupan en $M = 15$ bins de igual anchura según la confianza $\hat{c} = p(\hat{y} \mid \mathbf{x})$, donde $\hat{y}$ es la clase predicha. Para cada bin B_m, se compara la precisión media $\text{acc}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \mathbf{1}[\hat{y}_i = y_i]$ con la confianza media $\text{conf}(B_m) = \frac{1}{|B_m|} \sum_{i \in B_m} \hat{c}_i$, ponderando por el tamaño relativo de cada bin:

$$\text{ECE} = \sum_{m=1}^{M} \frac{|B_m|}{N_{\text{test}}} \big|\text{acc}(B_m) - \text{conf}(B_m)\big|. \tag{23}$$

  Un modelo perfectamente calibrado satisface $\text{ECE} = 0$.

Table 2: Métricas principales sobre el conjunto de test ($N_{\text{test}} = 33\,004$); ↑ indica métrica a maximizar, ↓ a minimizar. Las columnas *Refer.* y Acc_{ret} corresponden, respectivamente, a la tasa de derivación a revisión humana (percentil 85 de u_{epi}) y a la exactitud sobre el subconjunto automáticamente clasificado. El valor óptimo de cada columna se marca en negrita.

Modelo	AUC ↑	F1 ↑	Acc. ↑	ECE ↓	Brier ↓	NLL ↓	Refer.	Acc_{ret}
Determinista (MAP)	0.9923	**0.9547**	**0.9631**	0.0064	**0.0283**	0.1065	—	—
MC Dropout	0.9923	0.9519	0.9606	0.0049	0.0302	0.1094	15.07%	0.9904
Laplace (LL-KFAC)	**0.9924**	**0.9547**	**0.9631**	**0.0047**	**0.0283**	**0.1048**	15.08%	**0.9913**

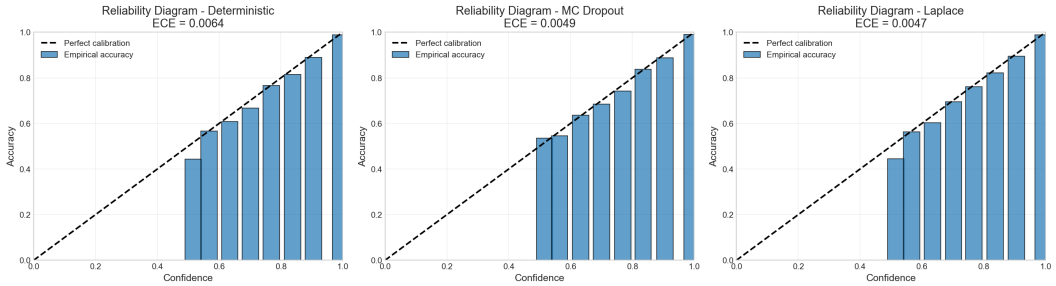

Figure 1: Diagramas de fiabilidad sobre el conjunto de test (15 bins uniformes sobre la confianza). La diagonal discontinua representa calibración perfecta. **Izquierda**: modelo determinista (MAP), $\text{ECE} = 0.0064$. **Centro**: MC Dropout, $\text{ECE} = 0.0049$. **Derecha**: aproximación de Laplace con GGN de última capa factorizado por Kronecker, $\text{ECE} = 0.0047$.

5 Resultados y discusión

En esta sección se presenta la evaluación de los modelos determinista, MC Dropout y aproximación de Laplace sobre el conjunto de test ($N_{\text{test}} = 33\,004$). Los dos modelos entrenados (determinista y MC Dropout) convergen en 25 épocas sin síntomas de sobreajuste; las curvas de entrenamiento (Apéndice B.1) muestran en ambos casos una pérdida de validación que sigue a la de entrenamiento hasta el final y un AUC de validación que se estabiliza en torno a 0.99.

5.1 Rendimiento y calibración

La Tabla 2 resume las métricas principales sobre el conjunto de test, incluyendo los indicadores de triaje que se discuten con más detalle en la Sección 5.3. En cuanto a capacidad de clasificación, los tres modelos presentan un empate práctico: AUC-ROC ≈ 0.9923, F1 ≈ 0.95 y *accuracy* ≈ 0.96, con diferencias perceptibles a partir de la cuarta cifra decimal. Esto indica que el hecho de incorporar la cuantificación de incertidumbre no compromete el poder discriminativo del clasificador base.

Las diferencias aparecen en calibración. La Figura 1 muestra que los tres modelos están muy por debajo del objetivo $ECE < 0.05$, pero Laplace obtiene el mejor resultado global ($ECE = 0.0047$, $NLL = 0.1048$), seguido muy de cerca por MC Dropout ($ECE = 0.0049$). El modelo determinista queda ligeramente por detrás ($ECE = 0.0064$). El Brier score sigue el mismo patrón: Laplace iguala prácticamente al baseline determinista, mientras que MC Dropout incurre una penalización leve. En conjunto, estos resultados sugieren que la principal ventaja del tratamiento bayesiano en este problema no está en mejorar la discriminación, sino en producir probabilidades mejor calibradas en las que se pueda confiar, especialmente en el caso de Laplace.

5.2 Comportamiento de la incertidumbre

Las métricas de calibración son una condición necesaria pero no suficiente para que una BNN sea útil: además, el modelo debe producir incertidumbres más altas cuando se equivoca. Para verificarlo, evaluamos la descomposición de la Sección 3.6 separando las predicciones correctas de las incorrectas.

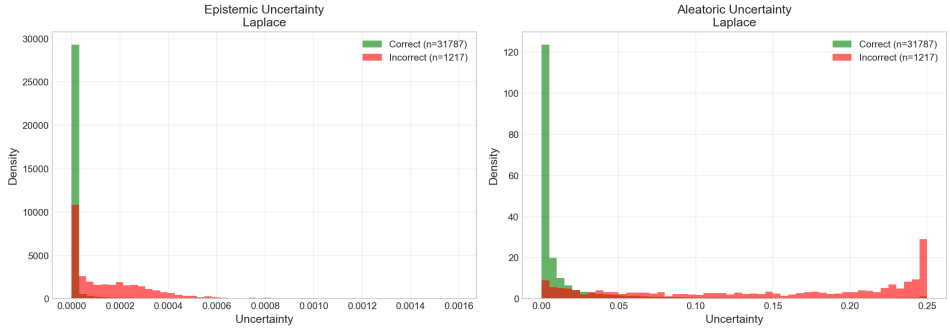

Figure 2: Distribuciones de incertidumbre epistémica (izquierda) y aleatoria (derecha) producidas por la aproximación de Laplace, separando predicciones correctas (verde, $n = 31\,787$) e incorrectas (rojo, $n = 1\,217$). La incertidumbre epistémica de las predicciones incorrectas es, en promedio, $13.07\times$ mayor que la de las correctas; para MC Dropout el factor análogo es $7.19\times$ (véase Apéndice B.3). La incertidumbre aleatoria, acotada por $0.25 = \max p(1-p)$ para Bernoulli, satura en los casos morfológicamente ambiguos y es dos órdenes de magnitud mayor que la epistémica en escala absoluta.

La incertidumbre epistémica separa aciertos y fallos. Para Laplace, la incertidumbre epistémica media sobre predicciones incorrectas (1.62×10^{-4}) es 13.07 veces superior a la media sobre las correctas (1.24×10^{-5}). Para MC Dropout, el mismo ratio es de 7.19. Por tanto, ambos métodos cumplen, la propiedad de 'saber cuándo no saben', aunque Laplace ofrece una separación notablemente más nítida. La Figura 2 muestra esta diferencia para Laplace: las predicciones correctas (en verde) se concentran en el primer bin ($u_{\text{epi}} \to 0$), mientras que las incorrectas (en rojo) se distribuyen sobre un rango mucho más amplio. Este patrón se observa también en MC Dropout (Apéndice B.3), aunque con menor separación relativa. Esta diferencia es coherente con el argumento teórico de la Sección 3.4: el Hessiano captura la curvatura exacta del log-posterior en $\boldsymbol{\omega}^*$, lo que se traduce en un estimador de varianza más fiel que las perturbaciones de *dropout*, cuya magnitud no se aprende.

La incertidumbre aleatoria es dominante en magnitud. En el panel derecho de la Figura 2 podemos ver un contraste esperable: u_{ale} alcanza valores cercanos a su máximo teórico $p(1-p) = 0.25$ para las muestras más ambiguas, mientras que u_{epi} se concentra en el intervalo $[0,\ 10^{-3}]$ (con dos órdenes de magnitud de diferencia). Esta asimetría cuadra con un régimen de gran volumen de datos: tras entrenar con alrededor de $154\,000$ parches, el posterior sobre los pesos está fuertemente concentrado, de modo que la incertidumbre residual procede casi íntegramente del ruido intrínseco de los datos. Esto justifica la decisión de emplear u_{epi} y no u_{tot} como señal de triaje: derivar a revisión humana las muestras con alta incertidumbre aleatoria no aporta valor, puesto que ningún modelo entrenado con más datos podría resolverlas.

5.3 Triaje clínico: clasificación selectiva

Para extraer valor de la cuantificación de incertidumbre, implementamos una política de triaje que deriva a revisión humana el porcentaje de casos más inciertos según la incertidumbre epistémica. Fijando τ_u en el percentil 85 de u_{epi}, se deriva a revisión humana el 15% de los casos más inciertos y se clasifica automáticamente el 85% restante.[1]

Reducción de falsos negativos. Sobre el 85% de los casos clasificados automáticamente, la exactitud sube de 96,31% (MAP sin triaje) a 99,13% (Laplace) y 99,04% (MC Dropout), como muestra la Tabla 2. La tasa de falsos negativos cae de $\sim 4.2\%$ a $\sim 1.1\%$ con Laplace y $\sim 1.0\%$ con MC Dropout, lo cual es un avance significativo. En términos absolutos, las variantes bayesianas permiten identificar 7-8 de cada 10 falsos negativos que emite el sistema determinista antes de que lleguen al usuario final, derivando los casos correspondientes a revisión humana.

[1] La calibración por percentiles, en lugar de mediante un umbral absoluto compartido, permite comparar ambos métodos a igual tasa de derivación pese a que la escala numérica de u_{epi} difiere entre ellos en dos órdenes de magnitud (percentil 85: 5.5×10^{-6} para Laplace, 1.1×10^{-4} para MC Dropout).

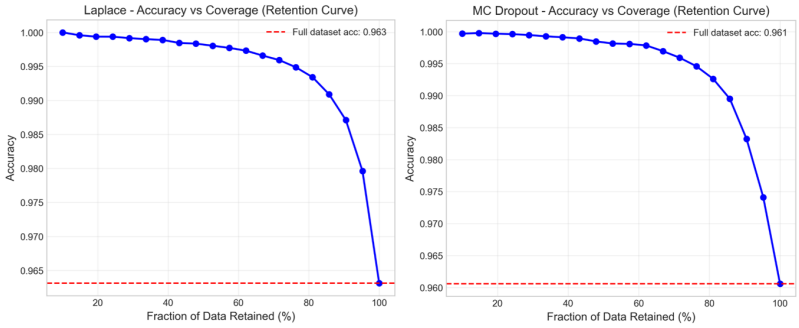

Figure 3: Curvas de retención (*accuracy vs. coverage*) para Laplace (izquierda) y MC Dropout (derecha). En cada punto, el modelo conserva la fracción indicada de las muestras más confiables según u_{epi} y la exactitud se evalúa únicamente sobre ese subconjunto. La línea discontinua horizontal marca la exactitud del dataset completo (0.963 para Laplace, 0.961 para MC Dropout). La monotonía confirma que la incertidumbre epistémica ordena correctamente los errores; ambos métodos exhiben curvas casi indistinguibles a pesar de diferir en dos órdenes de magnitud en la escala absoluta de u_{epi}.

Curvas de retención. La Figura 3 muestra las curvas de retención (*accuracy* frente a *coverage*) para los dos métodos bayesianos. En ambos casos la curva es monótona creciente al reducir la cobertura (lo cual es necesario para que una política de clasificación selectiva tenga sentido), y ambas curvas son prácticamente indistinguibles entre sí: cuando se retiene el $\sim 80\%$ de las muestras más confiables se alcanza $\sim 99\%$ de exactitud. Cabe destacar que el percentil de corte es un parámetro operativo clave que determina el volumen de casos derivados a revisión humana y la calidad del subconjunto clasificado automáticamente. Reducir el percentil de corte (e.g., al 80%) incrementaría la exactitud sobre el subconjunto retenido a costa de derivar más casos a revisión humana, mientras que aumentarlo (e.g., al 90%) haría lo contrario.

Inspección cualitativa. El análisis visual (cualitativo) del *top*-12 de muestras con mayor incertidumbre epistémica (Apéndice B.4) csugiere que la incertidumbre tiende a concentrarse en casos visualmente más complejos. Algunos de los posibles factores que podrían estar influyendo incluyen la presencia de artefactos de digitalización, desigualdades en la tinción, o la localización del tejido tumoral cerca de los bordes de la región central en muestras positivas Las probabilidades predichas en estos casos se sitúan muy cerca de la frontera de decisión ($p \in [0.33,\, 0.74]$ para Laplace), y la exactitud sobre el *top*-20 cae al 65% (Laplace) y 45% (MC Dropout) frente al 96,3% global. Esto refuerza la interpretación del triaje: los ejemplos que el modelo considera más inciertos son precisamente los que más se benefician de revisión humana.

5.4 Eficiencia computacional

La Tabla 3 resume un *benchmark* controlado de inferencia sobre 20 batches de test previamente cargados en GPU, con el fin de excluir el coste del `DataLoader` y medir únicamente el cómputo del modelo. En este escenario, el modelo determinista es el más rápido (0,179 s para 1280 imágenes), mientras que la ruta probabilística media de Laplace basada en GLM-probit mantiene una latencia muy cercana (0,201 s). Cuando se incluye también la estimación de incertidumbre, Laplace alcanza 0,448 s, aproximadamente $2{,}5\times$ el coste del baseline, pero sigue siendo muy inferior a MC Dropout, que requiere 8,831 s debido a sus 50 pasadas estocásticas. En conjunto, estos resultados indican que la aproximación de Laplace ofrece un compromiso favorable entre coste y utilidad probabilística: la probabilidad media puede obtenerse con una sobrecarga mínima respecto al modelo determinista, y la inferencia completa con incertidumbre sigue siendo mucho más eficiente que MC Dropout.

6 Conclusiones

Este trabajo ha comparado un clasificador determinista (MAP), la aproximación de Laplace *post-hoc* (LL-KFAC) y MC Dropout sobre una misma ResNet18 aplicada a la detección de cáncer histopatológico. Los tres métodos son indistinguibles en discriminación (AUC ≈ 0.9923), lo que confirma

Table 3: Benchmark controlado de inferencia sobre 20 batches de test (1280 imágenes) previamente cargados en GPU. Se reporta la media de 10 repeticiones tras 3 iteraciones de *warm-up*. "Laplace (media)" corresponde a `predict_proba` con regla GLM-probit, mientras que "Laplace (completo)" corresponde a `predict_with_uncertainty`.

Modelo	Tiempo total (s)	ms/imagen	Relativo al MAP
MAP	0,179	0,140	1,00×
Laplace (media)	0,201	0,157	1,12×
Laplace (completo)	0,448	0,350	2,50×
MC Dropout	8,831	6,899	49,29×

que la cuantificación de incertidumbre no degrada el clasificador base. Las diferencias aparecen en calibración: Laplace obtiene el mejor ECE (0.0047), Brier y NLL, y separa las incertidumbres de aciertos y fallos con un ratio de $13.07\times$ frente a $7.19\times$ de MC Dropout, en coherencia con la mayor fidelidad del Hessiano GGN al log-posterior local. La descomposición aleatoria–epistémica muestra que, en este régimen de datos abundantes, la incertidumbre residual es mayoritariamente aleatoria, lo que justifica emplear u_{epi} como señal de triaje: derivando el 15% de los casos más inciertos, la tasa de falsos negativos cae de $\sim 4.2\%$ a $\sim 1\%$. Las curvas de retención de ambos métodos son prácticamente indistinguibles, de modo que la elección entre ellos en un despliegue real dependería de criterios técnicos —Laplace es *post-hoc* y reduce el tiempo de inferencia a la mitad respecto al determinista; MC Dropout es más sencillo de integrar en arquitecturas con dropout pero multiplica ese tiempo por 2.7.

Las principales limitaciones del estudio son el carácter local y unimodal de la aproximación gaussiana de Laplace, la restricción a la última capa, la elección manual de la tasa de dropout en MC Dropout, y la evaluación sobre un único dataset que no garantiza generalización ante cambios de protocolo de tinción o equipo de digitalización. Como trabajo futuro, resultaría de interés comparar con Deep Ensembles, explorar Laplace sobre capas más profundas del backbone, y calibrar τ_u con retroalimentación clínica directa para optimizar la tasa de derivación sobre una métrica de negocio real.

References

Erik Daxberger, Agustinus Kristiadi, Alexander Immer, Runa Eschenhagen, Matthias Bauer, and Philipp Hennig. Laplace Redux – Effortless Bayesian Deep Learning. In *Advances in Neural Information Processing Systems*, volume 34, pages 20089–20103. Curran Associates, Inc., 2021. URL `https://proceedings.neurips.cc/paper/2021/hash/a7c9585703d275249f30a088cebba0ad-Abstract.html`.

Yarin Gal and Zoubin Ghahramani. Dropout as a Bayesian Approximation: Representing Model Uncertainty in Deep Learning. In *Proceedings of the 33rd International Conference on Machine Learning*, volume 48 of *Proceedings of Machine Learning Research*, pages 1050–1059. PMLR, 2016. URL `https://proceedings.mlr.press/v48/gal16.html`.

Tilmann Gneiting and Adrian E. Raftery. Strictly Proper Scoring Rules, Prediction, and Estimation. *Journal of the American Statistical Association*, 102(477):359–378, 2007. doi: 10.1198/016214506000001437.

A Estudio de diferentes métodos de inferencia aproximada

La tabla 4 resume los compromisos prácticos que motivan la elección de Laplace y MC Dropout, complementando la explicación de la Sección 2.3.

Table 4: Compromisos entre métodos de inferencia aproximada en BNN. T denota el número de muestras en inferencia y M el tamaño de un *ensemble*.

Método	Coste entren.	Coste inf.	Reentren.	Cobertura del posterior
Laplace (*post-hoc*)	$1\times + 1$ *fit*	T	No	Local, unimodal
MC Dropout	$1\times$	T	Sí	Local, unimodal
Inferencia variacional (MFVI)	$\sim 2\times$	T	Sí	Unimodal
Deep Ensembles	$M\times$	M	Sí	Multimodal
MCMC (SGLD, HMC)	$\gg 1\times$	T	Sí	Asintóticamente exacta

B Material complementario

B.1 Curvas de entrenamiento

La Figura 4 muestra la evolución de la pérdida y del AUC en entrenamiento y validación para los dos modelos entrenados. En ambos casos la pérdida de validación sigue monótonamente a la de entrenamiento sin el cruce característico del sobreajuste, y el AUC de validación alcanza la meseta cerca del final de las 25 épocas. El *early stopping* configurado con paciencia 5 no se activa, lo cual indica que el horizonte de 25 épocas está bien dimensionado para esta combinación de arquitectura y dataset.

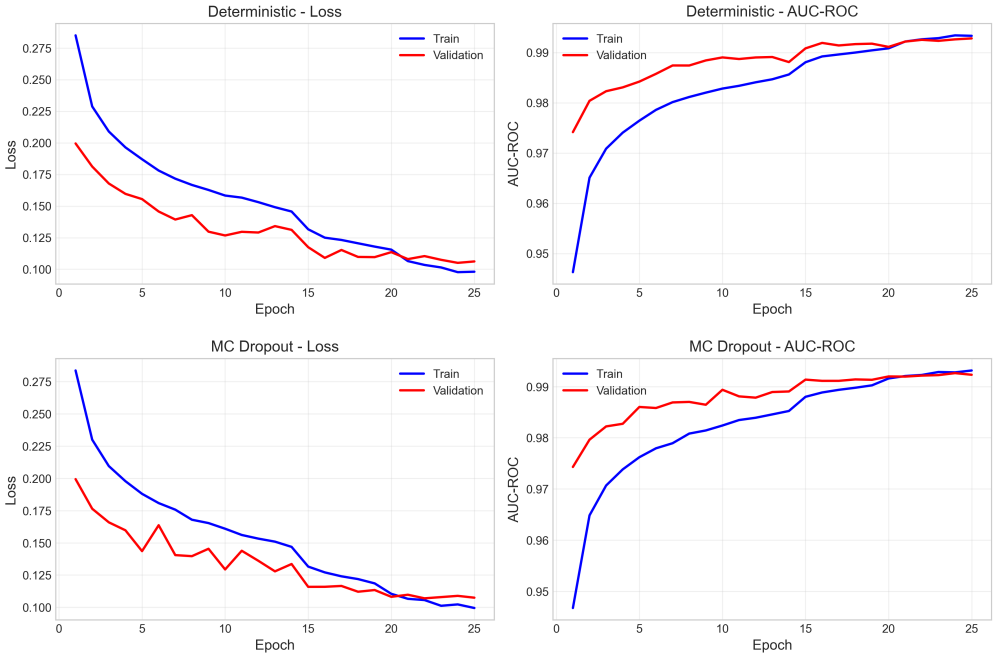

Figure 4: Curvas de entrenamiento. **Arriba**: modelo determinista (MAP). **Abajo**: modelo MC Dropout. En cada par, pérdida de *cross-entropy* (izquierda) y AUC-ROC (derecha) sobre entrenamiento (azul) y validación (rojo).

B.2 Curvas ROC

La Figura 5 muestra las curvas ROC de los tres modelos sobre el conjunto de test. La superposición visual confirma la coincidencia numérica reportada en la Tabla 2: las diferencias en AUC se sitúan en la cuarta cifra decimal y no son visibles a esta escala.

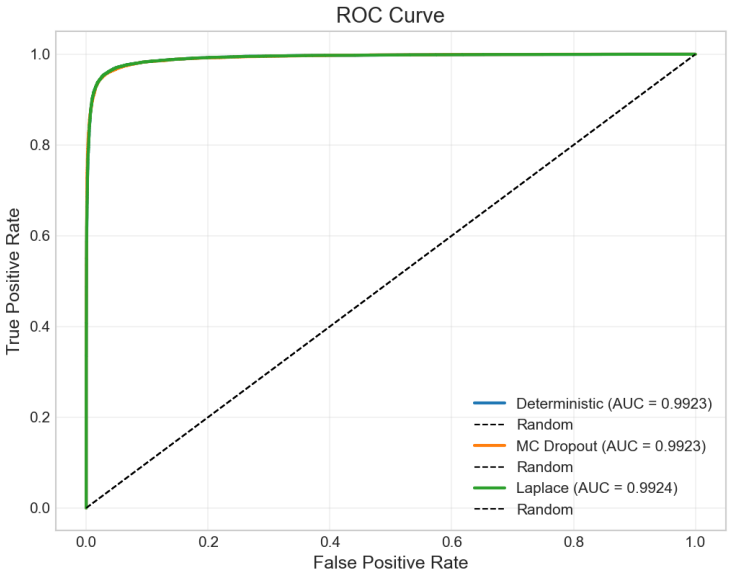

Figure 5: Curvas ROC sobre el conjunto de test. Las tres curvas son visualmente indistinguibles, con AUC ≈ 0.9923 para los tres métodos.

B.3 Distribución de incertidumbre para MC Dropout

La Figura 6 reproduce la Figura 2 para MC Dropout. El patrón cualitativo es idéntico —las predicciones correctas se concentran en $u_{\text{epi}} \to 0$, las incorrectas se distribuyen sobre un soporte más amplio— pero la separación es menor en términos relativos: el ratio entre las medias de u_{epi} sobre incorrectas y correctas es $7.19\times$ para MC Dropout frente a $13.07\times$ para Laplace.

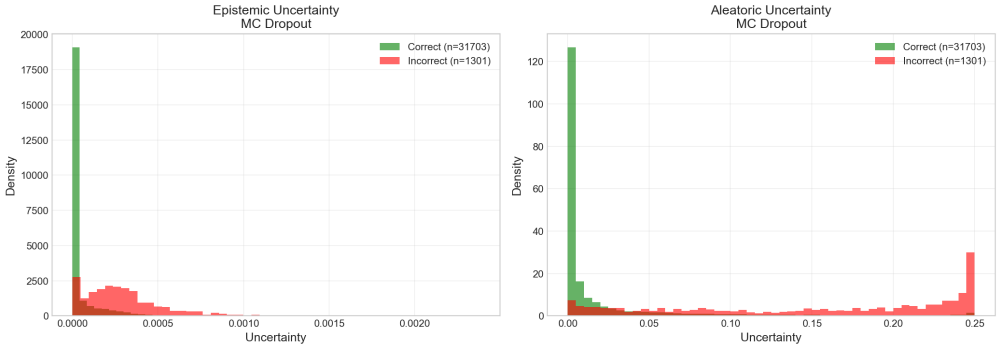

Figure 6: Distribuciones de incertidumbre epistémica (izquierda) y aleatoria (derecha) producidas por MC Dropout, separando predicciones correctas (verde, $n = 31\,703$) e incorrectas (rojo, $n = 1\,301$).

B.4 Muestras con mayor incertidumbre epistémica

Las Figuras 7 y 8 muestran el *top*-12 de parches de test ordenados por u_{epi} decreciente para Laplace y MC Dropout respectivamente. En ambos casos, las probabilidades predichas se concentran cerca de 0.5 y los parches presentan características visualmente ambiguas: mezcla de morfologías, artefactos o presencia de tejido cuya etiqueta depende críticamente de la región central de 32×32. Esta inspección cualitativa apoya la interpretación de la Sección 5.3: los casos con u_{epi} alta son aquéllos en los que un patólogo humano también dudaría, de modo que su derivación a revisión tiene sentido clínico.

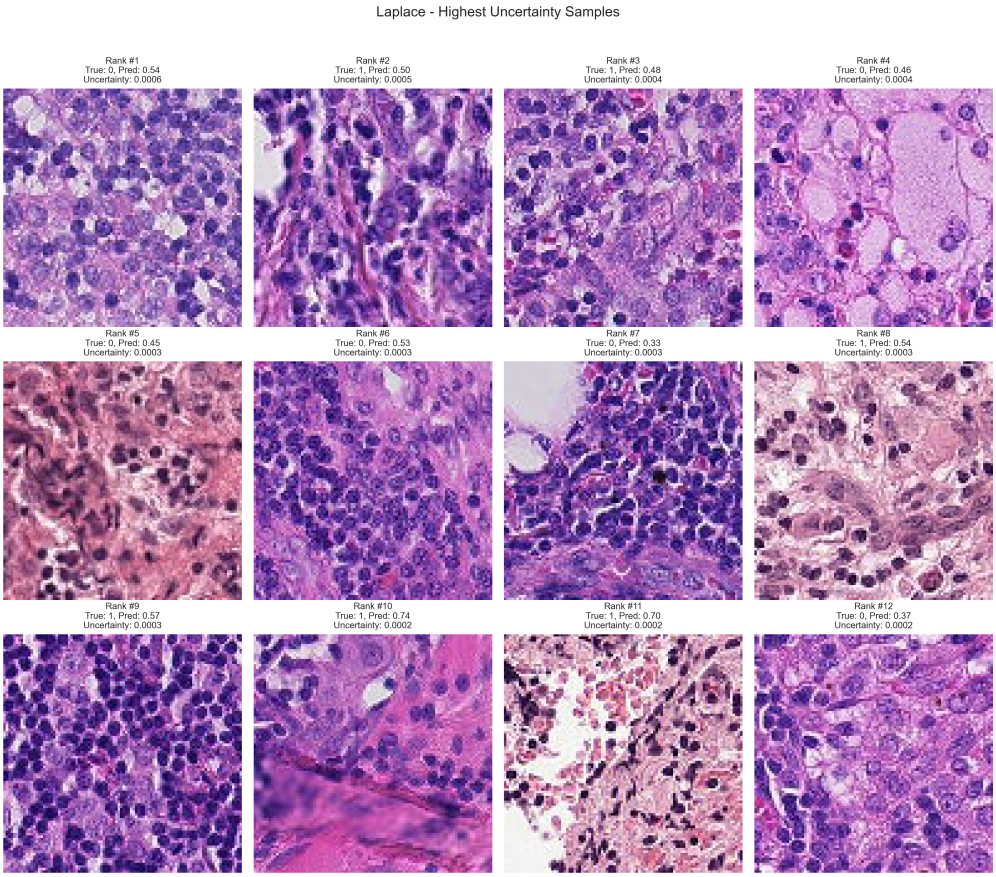

Figure 7: Top-12 de parches de test ordenados por incertidumbre epistémica decreciente según Laplace. Cada cuadro indica la etiqueta real, la probabilidad predicha y el valor de u_{epi}.

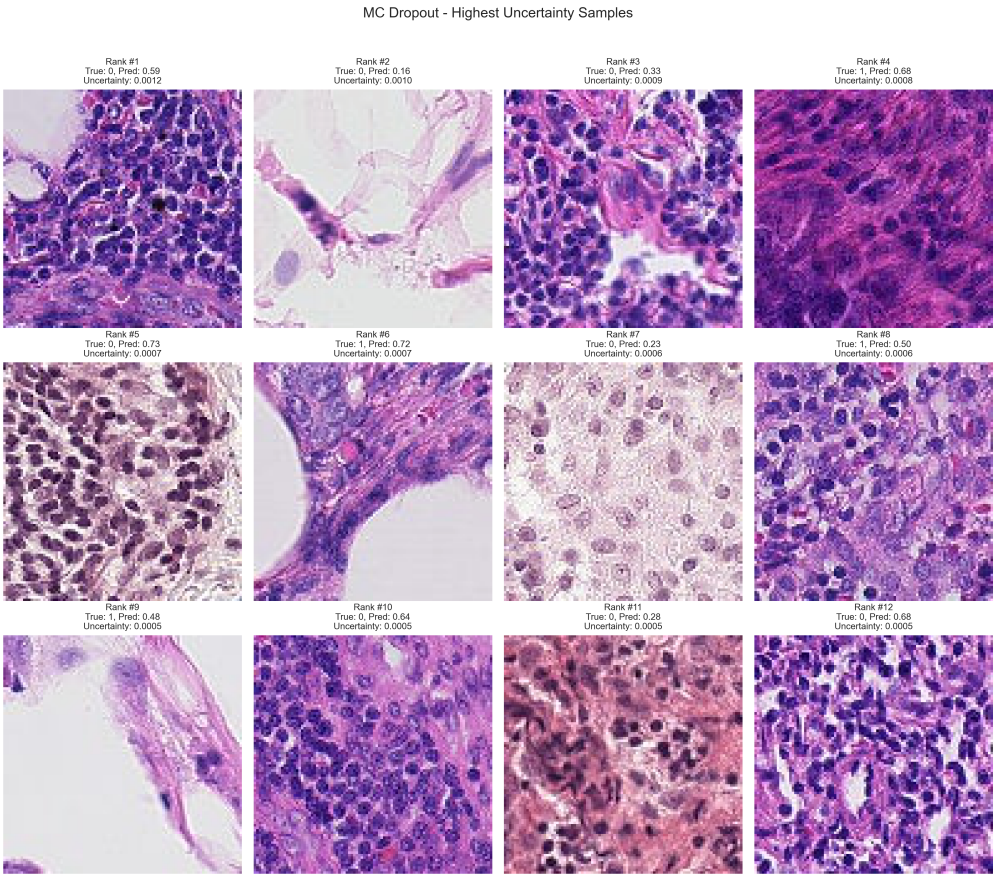

Figure 8: Top-12 de parches de test ordenados por incertidumbre epistémica decreciente según MC Dropout. Misma codificación que la Figura 7.